

# LLM 기반 자기소개서 상시 첨삭 및 직무 적합도 피드백

곽도원 hegnut5859@gmail.com 성균관대학교 수원시, 대한민국	박민호 parkminho00000@gamil.com 성균관대학교 수원시, 대한민국	박성민 jumis007@gmail.com 성균관대학교 수원시, 대한민국
송태현 codream00@gmail.com 성균관대학교 수원시, 대한민국	이상엽 skkulsy0117@naver.com 성균관대학교 수원시, 대한민국	

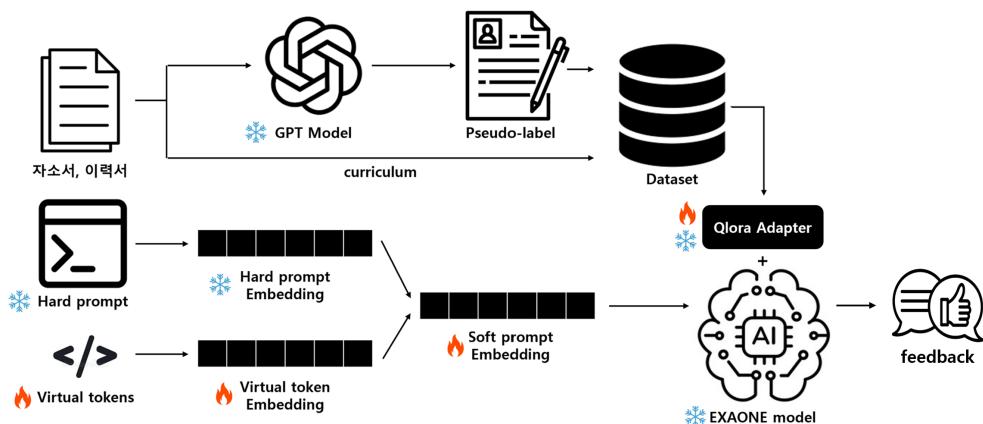


Figure 1: DPO-UA (Dynamic Prompt Optimization for User-Aware) feedback framework

[https://github.com/AIProjectTeam1/final\\_project](https://github.com/AIProjectTeam1/final_project)

## ABSTRACT

기존 이력서, 자기소개서 피드백 시스템은 주로 오탈자 수정이나 문장 구성 등 형식적 측면에 국한된 진단만을 제공하며, 지원자의 역량이나 직무 적합성에 대한 의미 있는 개선을 유도하지 못하는 한계가 있다. 이러한 내용 기반 피드백의 부재는 이력서가 실질적인 경쟁력 확보 수단으로 기능하기 어렵게 만든다. 본 연구는 이러한 한계를 극복하기 위해, 지원자 정보를 활용한 동적 프롬프트 최적화 구조인 DPO-UA(Dynamic Prompt Optimization for User-Aware) feedback framework를 제안한다. DPO-UA는 pseudo-label 기반 사용자 정보 주입, 프롬프트 학습 구조, 그리고 피드백 난이도 기반 계층 학습을 결합해, 맥락에 적합하고 정밀한 피드백 생성을 가능하게 한다. 제안한 방법으로 학습된 모델은 자기소개서와 이력서에 대한 피드백을 동시에 진행하여 피드백 품질을 효과적으로 향상시켰다.

## KEYWORDS

feedback model, soft prompt, pesudo-labeling, LLM

## ACM Reference Format:

곽도원, 박민호, 박성민, 송태현, and 이상엽. 2025. LLM 기반 자기소개서 상시 첨삭 및 직무 적합도 피드백. In . ACM, New York, NY, USA, 5 pages. <https://doi.org/10.1145/nnnnnnnn.nnnnnnnn>

## 1 INTRODUCTION

이력서와 자기소개서는 지원자의 역량, 경험, 직무 적합성을 효과적으로 전달해야 하는 핵심 문서로, 그 품질은 채용 과정의 성패를 좌우할 수 있다. 이에 따라 다양한 자동화 기반 피드백 시스템이 등장하고 있으나, 대부분 맞춤법, 문장 구성, 레이아웃 등 형식적 요소에 국한된 피드백만을 제공한다. 이러한 접근은 이력서의 본질적인 목적, 즉 지원자의 강점이 목표 직무에 어떻게 부합하는지를 설득력 있게 표현하는 데 충분히 기여하지 못하며, 실질적인 개선 방향을 제시하는 데 한계를 보인다.

특히 현존 시스템은 지원자의 배경, 지원 분야, 경력 수준 등 맥락 정보를 반영하지 못해 피드백이 획일적이고 비문맥적으로 생성되는 문제가 있다. 이러한 한계를 극복하기 위해 단순한 문장 교정을 넘어, 개별 상황과 목표에 맞춘 의미 중심 피드백을 자동 생성할 수 있는 새로운 접근이 필요하다.

본 연구에서는 지원자 정보를 pseudo-label 형태로 가공하여 입력에 주입하고, 프롬프트를 고정하지 않고 학습 과정에서 동적으로 최적화하는 DPO-UA (Dynamic Prompt Optimization for User-Aware) framework를 제안한다. DPO-UA는 사용자 맥락을 반영한 동적 프롬프트 구성과 피드백 난이도 기반 계층 학습 전략을 결합함으로써, 모델이 다양한 수준의 피드백을 점진적으로 학습하고 생성할 수 있게 한다. 이를 통해 단순한 형식적 오류 진단을 넘어, 지원자 맥락을 구조적으로 반영함으로써 피드백 품질을 실질적으로 향상시킨다.

## 2 RELATED WORK

### 2.1 Large Language Model

**Gemma-2B-ko**는 경량 구조 기반의 모델로, 다양한 한국어 테스트에서 안정적인 성능을 보이며 자기소개서 문장 생성 및 수정에 사용된 사례가 있다. 특히 간단한 피드백 생성이나 구조적 오류 교정에 효율적인 결과를 보인다.

**LGAI-EXAONE** 모델은 2B 파라미터 규모의 대형 한국어 특화 모델로, 동일 크기 대비 한국어 문장 생성 품질이 우수하며, 문맥을 고려한 정교한 피드백 생성에도 강점을 보인다. 특히 지원자의 배경, 직무 정보 등 맥락 정보를 함께 반영해야 하는 피드백 과제에 있어 더욱 적합한 특성을 갖는다. 본 연구에서는 이러한 특성을 고려하여, 최종적으로 **LGAI-EXAONE**을 기반 모델로 채택하였다.

### 2.2 Resume Feedback Dataset

피드백 생성 과제를 수행하면서 자기소개서 및 이력서 본문뿐 아니라, 지원자의 배경 정보와 직무 관련 데이터를 포함한 고품질 데이터셋이 필요하다. 이를 위해서는 실제 지원 문서, 피드백 이력, 채용 공고 등의 자료가 요구되나, 한국어 기반의 공개 이력서 피드백 데이터셋은 거의 존재하지 않는다.

**Crawling**은 이력서 및 자기소개서 확보 방법 중 하나지만, 법적·정책적 한계가 따른다. 링커리어와 같은 플랫폼은 개별 페이지 크롤링은 허용하더라도 전체 사이트에 대한 수집은 금지되어 있어, 수집된 데이터를 학습에 활용하는 데 제약이 있다.

AI 기반 가상 데이터셋으로는 **Resume-Matching-Dataset-v2**가 있다. 이는 GPT-4o-mini를 활용해 생성된 자기소개서, 이력서, 채용공고, 피드백 시나리오를 포함하며, 개인정보 없이 실제 취업 흐름을 반영한다는 점에서 LLM 기반 피드백 생성 모델 학습에 적합하다. 본 연구는 해당 데이터셋을 기반으로 pseudo-label 생성, 계층 학습, 프롬프트 최적화 등의 실험을 수행하였다.



Figure 2: Resume-Matching-Dataset-v2

### 2.3 Quantitative Evaluation

이력서 및 자기소개서 피드백 생성 모델의 성능을 정량적으로 평가하기 위해, 기존 연구에서는 주로 의미 유사도 기반 지표가 활용된다. **BERTScore**는 사전학습 언어 모델의 토큰 임베딩을 사용해 기준 문장과 생성 문장 간 의미 유사도를 계산하며, n-gram 기반 지표보다 문맥 반영에 유리하나, 문장 전체 의미를 포착하는 데는 한계가 있다.

**KoSBERT-NLI**는 자연어 추론 데이터로 학습되어 어휘 일치 이상의 깊이 있는 의미 유사도 측정에 강점을 가지며, 생성 문장이 기준 문장과 유사한 의미를 내포하는지를 보다 정밀하게 평가할 수 있다. 따라서 본 연구는 문장 단위 의미 평가의 정확성을 확보하기 위해 **KoSBERT-NLI** 기반 유사도 점수를 정량적 성능 평가 지표로 채택하였다.

## 3 METHOD

**DPO-UA(Dynamic Prompt Optimization for User-Aware) feedback framework**는 QLoRA를 사용한 LLM 기반 fine-tuning 구조를 따르며, 사용자 맥락을 반영한 피드백 생성을 목표로 세 가지 핵심 전략을 결합하였다: (1) pseudo-label 기반 사용자 정보 주입, (2) 난이도 기반 계층 학습, (3) 프롬프트 학습 기반 동적 최적화

### 3.1 Pseudo-label 기반 사용자 정보 주입

기존 이력서·자기소개서 피드백 시스템은 문장 구조, 어휘 선택, 맞춤법 등 표면적 요소에 집중하며, 사용자 맥락이나 배경 정보를 반영하지 못하는 한계를 지닌다. 이로 인해 피드백은 문장의 의미나 사용자의 목표와 무관하게 일반적인 수준에 머무른다. 본 연구는 사용자 맥락 정보를 프롬프트에 명시적으로 주입하는 방식으로 학습 구조를 개선하였다.

**Pseudo-label** 기반 사용자 정보 주입은 대형 언어모델을 활용해 사용자 정보를 자동 추출하고, 이를 프롬프트에 삽입함으로써 문장의 맥락과 목적을 함께 고려하도록 유도한다. 이는 LLM이 단순히 문장을 평가하는 것을 넘어, "누가", "무엇을 위해", "어떤 배경을 갖고 작성했는가"에 기반한 의미 중심 피드백 생성을 가능하게 한다. 이를 위해 우리는 GPT-3.5를 활용하여 이력서와 자기소개서 원문으로부터 다음의 정보를 자동 추출하였다.

- **Keyword Analysis:** 지원자의 가치관, 동기, 관심사를 반영하는 핵심 키워드
- **Job Analysis:** 직무명, 필수 및 우대 기술, 직무 요건과 책임 등 공고 기반 정보
- **Resume Analysis:** 지원자의 요약 경력, 보유 기술, 학력, 프로젝트, 기타 일반 정보

이 구조는 fine-tuning 학습 과정 뿐만 아니라 추론 단계에도 적용되어, 문장 자체의 완성도가 아닌 직무 맥락과 사용자 정보를 중심으로 평가할 수 있도록 모델의 피드백 방식을 전환하는 데 기여한다.

구분	항목	내용
keyword analysis		웹 개발 열정, 협업 능력, 기술 습득 의지, 프로젝트 경험...
job analysis	지원 직무	프론트엔드 엔지니어
	필수 기술	HTML, CSS, JavaScript, SCSS, Axios, Vite, 기술 검토, 코드 리뷰
	우대 기술	Vuex, RESTful API, 크로스 브라우징, 반응형 디자인, JIRA, Trello
	직무 요건	HTML, CSS 기본 이해, Vue.js 프로젝트 경험, SCSS 스타일링 경험...
resume analysis	직무 책임	Vue.js 개발, SCSS UI 구현, Axios API 연동...
	요약 경력	개인 웹사이트 개발, Vue.js 강의 수강, Git 팀 프로젝트
	보유 기술	HTML, CSS, JavaScript, Vue.js, Git...
	프로젝트	Vue.js 강의 기반 프로젝트...
	학력	ZZ대학교 정보기술학과 졸업...
	기타	영어 능력 및 외부 활동 정보 없음

Table 1: 지원자 정보 pseudo-label 예시

### 3.2 난이도 기반 계층 학습

기존 이력서 피드백 모델은 다양한 품질의 자소서를 함께 학습하기 때문에, 명확한 문제를 가진 문장과 복합적 문장이 혼재된 상태에서 학습이 진행되어 수렴 편향이 발생할 수 있다. 이러한 문제를 완화하고 모델의 일반화 능력을 높이기 위해, Curriculum Learning 기반의 난이도 기반 계층 학습 전략을 도입하였다.

핵심 가정은, 모델이 먼저 명확히 구분되는 고/저품질 자소서를 학습하면, 이후 애매하고 복잡한 문장에 대해서도 보다 안정적으로 피드백을 생성할 수 있다는 것이다. 이를 위해 자소서 품질 점수(selfintro\_score)를 기준으로 전체 데이터를 두 단계로 구분하여 학습하였다:

- **Level 1:** 상위 25% (우수 자소서)와 하위 25% (부족한 자소서) - 명확하게 긍정 혹은 부정적인 피드백을 유도할 수 있는 데이터
- **Level 2:** 중간 50% 구간 (25-75%) - 긍부정이 혼합되어 복합적이거나 해석이 요구되는 데이터

이러한 계층 구조는 모델이 먼저 정답이 명확한 샘플을 학습함으로써 안정적인 초기 수렴을 유도하고, 이후 복잡한 샘플로 학습 범위를 넓혀가는 방식으로 구성되었다. 이를 기반으로 Level 1의 데이터를 활용해 1차 학습을 진행한 뒤, Level 2의 데이터를 활용해 2차 학습을 진행하는 방식으로 학습이 이루어진다.

### 3.3 프롬프트 학습 및 동적 최적화

대규모 언어 모델(LLM)은 입력 프롬프트에 매우 민감하게 반응하는 경향이 있으며, 동일 문장이라도 프롬프트의 표현 방식이나 순서에 따라 생성 결과가 크게 달라질 수 있다. 특히 다양한 직무, 경험 수준, 표현 스타일을 가진 지원자의 데이터를 학습할 경우, 고정된 프롬프트 구조는 유연한 대응에 한계를 보인다. 따라서 **soft prompt tuning** 기법을 적용하여, 모델이 입력 문맥에 따라 동적으로 최적화된 프롬프트를 스스로 구성할 수 있도록 하였다.

초기에는 get\_peft\_model을 사용하여 LoRA가 적용된 모델 위에 prompt tuning을 추가하려 했으나, 가상 토큰 삽입 및 손실 계산 과정에서 오류가 발생하였다. 이는 Trainer가 복수의 PEFT 구조를 안정적으로 처리하지 못하기 때문이었다. 이에 따라 학습 구조를 다음과 같이 변경하였다:

- **QLoRA 모델 고정:** QLoRA로 사전 학습된 EXAONE 모델을 불러오고, 모든 파라미터를 고정하였다.
- **독립적인 Prompt 모듈 추가:** PromptTuningConfig로 정의된 가상 토큰 임베딩 레이어를 새로 생성하고, 학습 가능한 상태로 유지하였다.
- **Model Wrapper 구성:** ModelWithPrompt를 구현하여 forward 시 가상 토큰 임베딩과 입력 토큰 임베딩을 결합하고, 이를 고정된 LoRA 모델에 전달하였다.
- **커스텀 data collator:** PromptCollator를 통해 입력 시퀀스를 패딩하고, 가상 토큰에 해당하는 레이블은 -100으로 마스킹하였다.

이 구조는 downstream 학습 과정에서 기존 LLM 파라미터는 고정한 채 soft prompt만 업데이트되므로, 효율적인 학습이 가능하고 과적합 위험도 낮다. 이로 인해 전체 모델 파라미터를 수정하지 않고도 context-aware한 피드백 생성이 가능하며, 프롬프트를 별도로 재설계하지 않고도 최적의 프롬프트를 탐색할 수 있다는 이점이 있다.

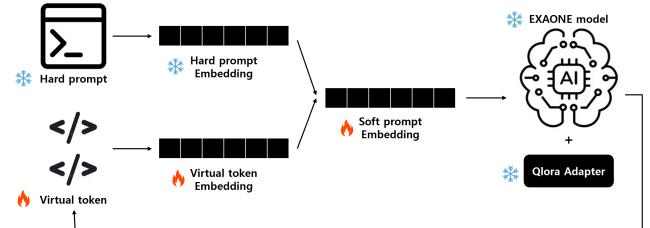


Figure 3: soft prompt tuning 학습 구조

## 4 EXPERIMENTS

**DPO-UA feedback framework**의 유효성을 실증적으로 평가하기 위해 총 5가지 실험을 설계하였으며, 각 구성 요소의 기여도를 분석하고 전체 시스템의 성능을 종합적으로 검증하고자 하였다. 실험은 모두 동일한 베이스 모델(LGAI-EXAONE)과 데이터셋(Resume-Matching-Dataset-v2)하에 진행되었으며, loss 변화와 이력서, 자소서 피드백 각각에 대한 KoSBERT-NLI 기반 정량 평가와 더불어, 정성적 분석을 병행하였다.

### 4.1 Zero-shot, Few-shot Prompting

사전 학습 없이 few-shot prompting만으로 자기소개서 피드백 생성이 어느 수준까지 가능한지를 정성적으로 평가하였다. 동일한 자기소개서 입력에 대해 (1) zero-shot, (2) one-shot, (3) two-shot 구성을 비교하였으며, 각 프롬프트는 구조와 문제를 일관되게 유지하였다. GPU 자원 문제로 three-shot 이상은 제외하였다.

Prompt Type	Generated Feedback (요약)
<b>Reference</b>	자기소개서는 구조가 잘 잡혀 있고, 논리적으로 작성되었습니다. 지원자는 본인의 경력과...
<b>Zero-shot</b>	하늘빛님의 자기소개서는 기술적 역량과 열정, 그리고 사용자 중심의 접근법을 잘 보여주는 훌륭한 예시입니다. 다음은 피드백과 개선 제안입니다: 긍정적인 점: 기술적 역량 강조: ...
<b>One-shot</b>	하늘빛의 자기소개서는 전반적으로 명확하고 구체적인 경험과 기술적 역량을 잘 보여주고 있어 긍정적인 인상을 줍니다. 각 항목별로 몇 가지 개선 사항과 추가적인 피드백을 제안해 드리겠습니다: #1) 마음을 담은 자기소개: 더 나은 사용자 경험을 위해 긍정적인 점:...
<b>Two-shot</b>	하늘빛 지원자의 자기소개서는 전반적으로 명확하고 구체적인 경험과 기술적 역량을 잘 보여주고 있습니다. 각 섹션에서 다음과 같은 개선 사항을 제안드립니다: 1) 자기소개 - 개선 사항: 자기소개 부분에서...

Table 2: Zero-shot, One-shot, Two-shot prompting 추론 결과

실험 결과, Table 2와 같이 전반적인 형식 일관성, 직무 적합성 반영, 그리고 사용자 맥락에 기반한 정교한 피드백 생성에는 한계가 존재하였다. 특히 긍정적인 점, 개선사항 1 등과 같이 실제 정답에는 존재하지 않는 형식의 피드백이 생성되었다. 이는 LLM에 내재된 사전 학습된 피드백 형식이 단순 추론 단계의 few-shot 예시를 제공하는 것만으로는 변경이 힘들다는 것을 의미한다. 따라서, 직무 맥락과 사용자 정보를 통합적으로 고려하는 fine-tuning 기반 학습 구조가 적합하다.

## 4.2 User Context Injection via Pseudo-label

사용자의 직무, 기술, 경력 수준 등은 피드백 생성에서 중요한 맥락 정보를 제공한다. 본 실험에서는 pseudo-label 형태로 구조화된 사용자 정보를 프롬프트에 삽입함으로써 다음 두 가지 효과를 검증하였다: (1) 학습 안정성 및 성능 향상, (2) 사용자 맥락 기반 피드백 생성 능력.

학습 안정성을 확인하기 위해, 사용자 정보를 포함한 baseline-finetune 모델과 포함하지 않은 non-contextual 모델을 비교하였다. Fig 4는 사용자 정보가 포함된 모델이 더 낮은 loss에서 안정적으로 수렴함을 보여준다.

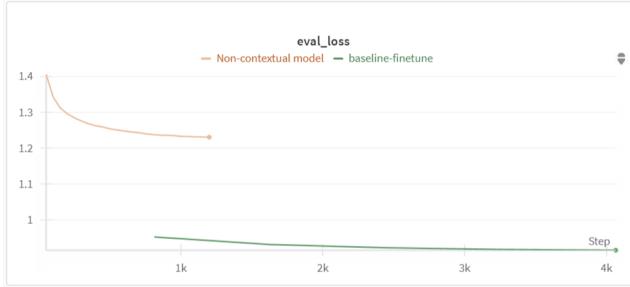


Figure 4: pseudo-label 삽입에 따른 loss 비교

Table 3는 사용자 정보 주입의 정량적 효과를 KoSBERT-NLI 점수로 비교한 결과를 보여준다. 사용자 정보를 사용하지 않은 경우 가장 낮은 성능을 보였고, 학습 시 pseudo-label을 적용한 경우 성능이 개선되었다. 학습과 추론 모두에서 pseudo-label을 활용할 때 이력서와 자기소개서 피드백 모두에서 가장 높은 유사도를 기록하였다. 이는 pseudo-label이 **text-guidance**로 작용해 모델이 사용자 의도와 표현 특성을 정확히 반영하고 추론 시점에서도 문맥적 합성과 응답 일관성을 높이는 데 기여함을 나타낸다.

Use User pseudo-label	Resume Score	Self-Intro Score
Not use	0.7899	0.8080
Train only	0.8260	0.8302
Train + Inference	<b>0.8482</b>	<b>0.8501</b>

Table 3: 사용자 맥락 정보 삽입 여부에 따른 유사도 비교

다음으로, 동일한 입력 문장에 대해 사용자 정보의 유무에 따른 출력 피드백을 비교하고, 생성된 피드백과 추출된 user label 간 의미 유사도를 측정하였다. Table 4에 나타나듯, 사용자 정보가 포함된 모델은 keyword, job, resume label과의 유사도에서 더 높은 값을 기록하였다. 이는 pseudo-label이 단순한 프롬프트 확장이 아니라, LLM이 맥락 기반 의미 판단과 직무 적합성 중심의 피드백 생성을 수행하는 데 실질적으로 기여함을 보여준다.

유저 정보 항목	사용자 정보 미포함	사용자 정보 포함
Keyword Label	0.8136	<b>0.8255</b>
Job Label	0.8186	<b>0.8203</b>
Resume Label	0.8214	<b>0.8372</b>

Table 4: pseudo-label과 피드백 유사도

## 4.3 Baseline Fine-Tuning + 계층 학습

Curriculum Learning 기법의 적용 여부가 피드백 학습에 미치는 영향을 분석한다. 전체 학습 데이터를 균등하게 섞어 일괄 학습한 기본 fine-tuning 모델을 비교군으로 설정해, 계층 학습을 적용한 모델과의 성능을 비교한다. 계층 학습 방법은 3.2의 설정을 따른다.

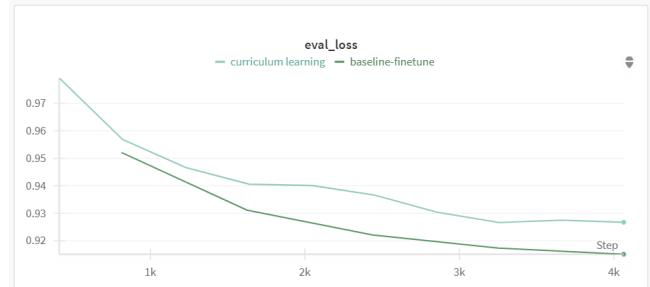


Figure 5: 계층 학습 기반 모델 loss

Configuration	Resume Score	Self-Intro Score
Baseline Fine-Tuning	0.8482	<b>0.8501</b>
Baseline Fine-Tuning + Curriculum Learning	<b>0.8491</b>	0.8276

Table 5: Fine-tuning, 계층 기반 모델 KoSBERT-NLI

실험 결과, 계층 학습을 적용한 모델은 일부 지표에서 긍정적 경향을 보였으나, 성능 향상은 제한적이었고 자기소개서 피드백에서는 점수가 오히려 하락했다. 이는 자소서·이력서 점수 기반의 단순한 난이도 계층이 표현 다양성과 정성적 요소가 중요한 자기소개서에 적절히 작동하지 않았음을 시사한다. 반면 이력서 피드백에서는 손실 감소 폭이 크고 유사도 점수도 소폭 상승하는 등, 일정 수준의 학습 효과가 확인되었다. 따라서 커리큘럼 기준을 의미 모호성, 문제 복잡도, 표현 다양성 등으로 확장한 다단계 계층 설계를 적용하면, 보다 안정적이고 일반화 가능한 학습이 가능할 것으로 보인다.

## 4.4 Soft Prompt 기반 동적 프롬프트 최적화

프롬프트 구성 방식에 따른 성능 차이를 분석하기 위해, 수작업 기반 hard prompt와 soft prompt 기반 동적 최적화를 비교하였다.

hard prompt는 직무 유형, 평가 목적, 표현 방식 등을 반영해 수작업으로 구성한 고정 프롬프트를 사용한다. 반면, soft prompt는 학습 가능한 임베딩 벡터를 num\_v개 hard prompt 앞단에 삽입하고, QLoRA, base model의 파라미터는 고정한 채 가상 임베딩만을 학습시킨다. soft prompt의 학습은 3.3의 설정을 따른다.

실험 결과, hard prompt는 구성 방식에 따라 성능 편차가 크게 나타나 프롬프트에 민감한 특성을 보였으며, 입력 문장 변화에 따라 품질이 일관되지 않았다. 반면, soft prompt는 프롬프트 임베딩을 학습을 통해 최적화함으로써 다양한 입력에 안정적이고 일관된 피드백을 생성했다. 특히, epoch=3, 16개 임베딩 벡터를 사용한 설정은 임베딩 수가 적고 학습이 부족했던 구성(epoch=1, 8개 벡터)보다 높은 유사도 점수와 문맥 적합성을 기록하였다. 이는 soft prompt가 학습량과 표현 용량이 증가할수록 사용자 정보와 입력 맥락을 더 정밀하게 반영할 수 있음을 보여준다.

Prompt(ep: epoch)	Resume Score	Self-Intro Score
Hard Prompt A	0.8281	0.8237
Hard Prompt B	0.8174	0.8259
Hard Prompt C	0.8330	0.8359
Soft Prompt(ep=1, num_v=8)	0.8392	0.8372
Soft Prompt(ep=3, num_v=16)	<b>0.8682</b>	<b>0.8598</b>

Table 6: hard/soft prompt 의미 유사도 비교

#### 4.5 Hyperparameter Tuning

모델 성능을 최적화하기 위해, wandb sweep을 활용한 **Bayesian Optimization** 방식으로 하이퍼파라미터 탐색을 수행하였다. 총 1000개 샘플을 기준으로 학습을 진행하였으며, 탐색 대상은 lr, epochs, gradient\_accumulation\_steps, lora\_r이다. 이때 batch size는 2로 고정하였으며, gradient\_accumulation\_steps와의 조합을 통해 effective batch size를 간접 조정하였다. 이는 제한된 GPU 메모리 환경에서 효율적인 학습을 가능하게 하기 위함이다.

Hyperparameter	최적 값 (Bayes 탐색 결과)
Learning Rate	4.869e-4
Epochs	5
Gradient Accumulation Steps	4
LoRA Rank ( $r$ )	16
Effective Batch Size	8

Table 7: Bayesian Optimization hyperparameter 탐색 결과

#### 4.6 종합 성능 비교 및 분석

모든 실험 결과를 정량적으로 종합한 결과는 Table 8에 요약하였다. 기본 fine-tuning 모델을 기준으로 사용자 정보 주입과 soft prompt 기반 동적 최적화를 적용한 결과, 각 요소가 성능 향상에 기여했음을 확인할 수 있다. 한편, 학습 안정화를 목표로 도입한 Curriculum Learning은 일부 loss 감소에는 기여했지만, 성능 향상에는 제한적인 효과를 보였다. 이는 현재 설정한 나이도 기준이 모델 일반화에 적절하지 않았기 때문으로 추정되며, 향후 보다 정교한 나이도 정의 및 샘플 구성 방식에 대한 재설계가 필요하다. 특히 soft prompt까지 적용된 최종 **DPO-UA framework** 적용 모델은 의미 유사도 기준 KoSBERT-NLI에서 **0.8682, 0.8598**을 기록하며 가장 우수한 성능을 나타냈다.

Configuration	Resume Score	Self-Intro Score
Basic Fine-tune	0.7899	0.8080
+ User Info Injection(train)	0.8260	0.8302
+ User Info Injection(test)	0.8482	0.8501
+ Curriculum Learning	0.8491	0.8276
+ Hard Prompt A	0.8281	0.8237
Hard Prompt B	0.8174	0.8259
Hard Prompt C	0.8330	0.8359
Soft Prompt(DPO-UA)	<b>0.8682</b>	<b>0.8598</b>

Table 8: 모델 구성별 KoSBERT-NLI 기반 정량 성능 비교

정성 평가 측면에서도, 동일한 입력 문장에 대해 최종 모델은 보다 구체적이고 직무 맥락에 적합한 피드백을 생성하는 경향을 보였다. Table 9은 베이스라인과 최종 모델의 출력 차이를 보여주는 예시로, 최종 모델이 단순한 평가에 그치지 않고 사용자 정보를 활용해 보다 상황에 맞는 피드백을 생성하는 것을 확인할 수 있다.

구분	출력 내용
이력서	이름: 정개발, 생년월일 (나이 만 24세), 전화번호: 010-****-1234, 이메일: devjang@xxmail.com, 학력: OO초등학교 졸업, OO중학교 졸업, OO고등학교 졸업...
Baseline	정개발의 이력서는 신입 개발자로서의 기본적인 자격 요건을 충족하고 있으며, 관련 프로젝트 경험에 있어 긍정적입니다. 그러나, 경력이 부족하고, 기술적 깊이가 부족한 점이 아쉽습니다. 특히, 지원하는 포지션에 대한 구체적인 경험에 부족하여 감점이 있었습니다.
DPO-UA	정개발 지원자의 이력서는 포지션에 적합한 기술과 경험을 잘 보여주고 있습니다. C# 및 .NET Core, SQL Server, RabbitMQ, Azure App Service 등 요구되는 기술 스택을 모두 갖추고 있으며, 게임 개발 동아리에서의 경험은 특히 긍정적입니다. 그러나, 경력이 신입 수준으로 제한적이며, 우대사항 중 RabbitMQ 사용 경험이 기본적인 수준에 그치고 있어 감점이 있었습니다. 전반적으로 이력서는 매우 우수하며, 포지션에 적합한 인재로 평가됩니다.

Table 9: 입력 문장에 대한 Baseline vs. DPO-UA 출력 비교

## 5 CONCLUSION

본 연구에서는 LLM 기반 이력서, 자기소개서 피드백 시스템의 품질을 개선하기 위한 **DPO-UA (Dynamic Prompt Optimization for User-Aware) Feedback framework**를 제안하였다. 기존의 단편적 문장 평가 접근을 넘어서기 위해, 우리는 사용자 정보 기반 프롬프트 구성, 계층적 학습 전략, soft prompt 기반의 프롬프트 최적화를 통합적으로 적용하였다.

실험 결과, 제안한 방법은 전반적인 학습 안정성과 피드백 표현의 정밀도 향상에 기여하였다. 특히 pseudo-label 기반 사용자 정보 주입은 단순한 문법 교정 수준을 넘어서, 지원자의 직무 맥락을 반영한 구체적 피드백을 가능하게 하였다. soft prompt 기반 프롬프트 최적화 역시 입력 다양성에 강건한 일관된 응답 생성을 가능하게 하며, 최종 모델의 성능을 크게 끌어올린 요소로 확인되었다.

한편, 나이도 기반 계층적 이해를 위해 적용한 Curriculum Learning은 일부 손실 감소에는 긍정적 영향을 주었으나, 평가 지표 측면에서는 제한된 효과를 보였다. 이는 현재 정의된 나이도 기준의 한계로 해석되며, 향후 보다 정교한 커리큘럼 설계 및 나이도 정량화 방식에 대한 보완이 요구된다.

향후에는 자기소개서 외에도 연구 계획서, 자기 PR 문서 등 다양한 문서 유형으로 확장하고, 사용자 반응 기반의 평가 및 강화 학습 기반 동적 튜닝 기법을 추가적으로 탐색함으로써, 실제 활용 가능한 고신뢰 피드백 시스템을 구축해 나갈 계획이다.